MODUL PRAKTIKUM 2

Preprocessing Teks (Pembersihan Data Teks Bisnis) dengan NLTK & Sastrawi

Mata Kuliah	AI Application for Business	**Kode / SKS**	SI401 / 2 SKS
Semester	Ganjil	**Program Studi**	Sistem Informasi - LPKIA

1. Tujuan Pembelajaran & Landasan Teori

Pada praktikum kedua ini, mahasiswa diharapkan mampu memahami dan mengimplementasikan teknik pemrosesan awal teks (Text Preprocessing) meliputi Case Folding, Tokenisasi (Tokenization), Stopwords Removal, dan Stemming pada dataset ulasan pelanggan bisnis menggunakan pustaka NLTK dan Sastrawi di Google Colab.

Analogi Konsep Preprocessing Teks Bisnis

Dalam dunia nyata, kalimat yang diketik oleh pelanggan saat memberi ulasan produk atau chat dengan Customer Service sering kali penuh dengan 'kebisingan' (noise) seperti penggunaan huruf kapital acak, tanda baca berlebih, typo, dan kata-kata sambung yang tidak relevan. Sebelum data teks dimasukkan ke dalam model AI/Machine Learning, teks tersebut harus 'dibersihkan' terlebih dahulu.

- **1. Case Folding:** Proses menyeragamkan seluruh huruf di dalam teks menjadi huruf kecil (lowercase) agar kata 'SANGAT', 'Sangat', dan 'sangat' terdeteksi sebagai kata yang sama.
- **2. Tokenization:** Proses memotong kalimat teks menjadi kumpulan kata-kata tunggal (tokens) atau potongan bermakna.
- **3. Stopwords Removal:** Proses membuang kata-kata umum yang sering muncul tetapi tidak membawa makna kunci dalam analisis bisnis (contoh: 'yang', 'di', 'dan', 'ke', 'dari').
- **4. Stemming:** Proses memotong imbuhan (awalan/akhiran) untuk mengembalikan suatu kata ke bentuk kata dasarnya (contoh: 'membeli', 'belian', 'pembelian' -> 'beli').

> 💡 **MENGAPA PREPROCESSING PENTING DALAM AI BISNIS?**• Meringankan Beban Komputasi: Menghapus kata-kata tidak penting mengurangi jumlah memori dan waktu latih model AI.
> • Meningkatkan Akurasi AI: Menghindari misinterpretasi model akibat perbedaan kapitalisasi atau kata berimbuhan.
> • Menyiapkan Data untuk Analisis Sentimen: Fokus hanya pada kata kunci emosi (seperti 'bagus', 'rusak', 'kecewa', 'murah').

2. Panduan Langkah Demi Langkah Menginstal Pustaka NLP di Colab

Bahasa Indonesia memerlukan pustaka khusus bernama Sastrawi untuk proses stemming dan stopwords removal. Ikuti langkah-langkah penyiapan lingkungan praktikum berikut:

- **1. Buka Notebook Praktikum:** Akses Google Colab Anda (colab.research.google.com) dan buat Notebook Baru dengan nama: Praktikum_02_[NIM]_[NamaMahasiswa].ipynb.
- **2. Instalasi Library Sastrawi:** Sastrawi tidak langsung tersedia di Google Colab. Buat Sel Kode baru (+ Code), lalu jalankan perintah: !pip install Sastrawi

- **3. Mengunduh Modul NLTK:** Pustaka NLTK memerlukan download resource punkt (untuk tokenisasi) dan stopwords standar.
- **4. Memastikan Eksekusi Tanpa Error:** Pastikan di bawah sel muncul tulisan 'Successfully installed Sastrawi' sebelum melanjutkan ke materi berikutnya.

3. Materi 1: Case Folding & Tokenisasi Data Ulasan Pelanggan

Pada materi ini, kita akan membersihkan data ulasan mentah dari pelanggan menggunakan teknik Case Folding (lowercase) dan Tokenisasi dengan pustaka NLTK.

Salinlah kode program Python berikut ke dalam Sel Kode (+ Code) di Google Colab Anda:

```
# ========================================
# 1. IMPORT LIBRARY & DOWNLOAD RESOURCE NLTK
# ========================================
import nltk
nltk.download('punkt')
from nltk.tokenize import word_tokenize
import re

# Data ulasan mentah dari pelanggan toko online
ulasan_mentah = "Pelayanan Toko SANGAT Cepat!! Saya Sangat PUAS Membeli Produk di Sini :-
)"

# ========================================
# 2. CASE FOLDING & HAPUS TANDA BACA
# ========================================
# Ubah ke huruf kecil semua (lowercase)
ulasan_lowercase = ulasan_mentah.lower()

# Hapus karakter selain huruf dan angka (tanda baca)
ulasan_clean = re.sub(r"[^a-zA-Z0-9\s]", "", ulasan_lowercase)

print('Teks Mentah    :', ulasan_mentah)
print('Hasil Cleaning :', ulasan_clean)

# ========================================
# 3. TOKENISASI (MEMOTONG MENJADI KATA)
# ========================================
tokens = word_tokenize(ulasan_clean)
print('Hasil Tokens   :', tokens)
```

Penjelasan Detail Baris Kode (Materi 1)

- • **import re :** Pustaka Regular Expression untuk mencari dan mengganti pola karakter teks (misalnya menghapus tanda baca).
- • **.lower() :** Method bawaan string Python untuk mengubah semua huruf menjadi huruf kecil.
- • **re.sub(r'[^a-zA-Z0-9\s]', '', ...) :** Menghapus semua simbol/tanda baca seperti '!!', ':-)', dan hanya menyisakan huruf, angka, serta spasi.

- • **word_tokenize(...) :** Fungsi NLTK untuk memotong kalimat menjadi daftar kata-kata tunggal (List of Tokens).

4. Materi 2: Stopwords Removal & Stemming Bahasa Indonesia (Sastrawi)

Pada materi kedua ini, kita akan menghilangkan kata-kata tidak penting (Stopwords) serta mengubah kata berimbuhan menjadi kata dasar menggunakan pustaka Sastrawi.

Buat Sel Kode baru (+ Code) di bawah sel sebelumnya, lalu ketik kode berikut:

```
# ========================================
# 1. INSTALASI & IMPORT LIBRARY SASTRAWI
# ========================================
# Tempatkan perintah !pip install Sastrawi di paling atas jika belum
from Sastrawi.StopWordRemover.StopWordRemoverFactory import StopWordRemoverFactory
from Sastrawi.Stemmer.StemmerFactory import StemmerFactory

# Teks masukan berupa ulasan komplain pelanggan
teks_ulasan = "Pelanggan sangat menyukai pelayanan yang diberikan oleh customer service
kami karena sangat membantu menyelesaikan permasalahan."

# ========================================
# 2. STOPWORDS REMOVAL (MENGHAPUS KATA HUBUNG)
# ========================================
factory_stop = StopWordRemoverFactory()
stopword_remover = factory_stop.create_stop_word_remover()
teks_tanpa_stopword = stopword_remover.remove(teks_ulasan.lower())

print('Teks Awal           :', teks_ulasan)
print('Tanpa Stopwords     :', teks_tanpa_stopword)

# ========================================
# 3. STEMMING (MENGAMBIL KATA DASAR)
# ========================================
factory_stem = StemmerFactory()
stemmer = factory_stem.create_stemmer()
teks_stemmed = stemmer.stem(teks_tanpa_stopword)

print('Hasil Akhir Stemming:', teks_stemmed)
```

Penjelasan Detail Baris Kode (Materi 2)

- • **StopWordRemoverFactory() :** Pembuat objek penghapus kata hubung standar Bahasa Indonesia milik Sastrawi.
- • **.remove(...) :** Method yang membuang kata-kata seperti 'yang', 'oleh', 'kami', 'karena' dari kalimat ulasan.
- • **StemmerFactory() :** Pembuat objek stemmer Bahasa Indonesia untuk memotong imbuhan.
- • **.stem(...) :** Method yang mengubah kata 'pelayanan' -> 'layan', 'diberikan' -> 'beri', 'membantu' -> 'bantu', dan 'menyelesaikan' -> 'selesai'.

5. Tugas Praktikum Harian (Latihan Mandiri)

Kerjakan latihan mandiri berikut secara individu di Google Colab untuk mempraktikkan pembersihan dataset ulasan bisnis Anda sendiri:

No	Instruksi Tugas Praktikum Pertemuan 2
1	Buatlah Sel Kode baru (+ Code) di bagian bawah notebook Praktikum_02 Anda.
2	Buatlah sebuah variabel berisi daftar (list) minimal 5 teks ulasan mentah pelanggan dari bidang bisnis yang Anda pilih di Pertemuan 1 (Contoh: ulasan makanan, ulasan sepatu, komplain pengiriman).
3	Terapkan langkah Case Folding (lowercase) dan hapus semua tanda baca dari kelima ulasan tersebut.
4	Lakukan Tokenisasi pada setiap ulasan yang telah dibersihkan.
5	Gunakan pustaka Sastrawi untuk melakukan Stopwords Removal dan Stemming sehingga menghasilkan kata-kata dasar saja.
6	Tampilkan hasil pembandingan sebelum dan sesudah preprocessing untuk setiap ulasan, lalu kumpulkan link Google Colab Anda ke LMS kampus.